State-of-the art техники RAG на примере победного решения Enterprise RAG Challenge и его адаптации

Акимов Дмитрий

Актуальность RAG

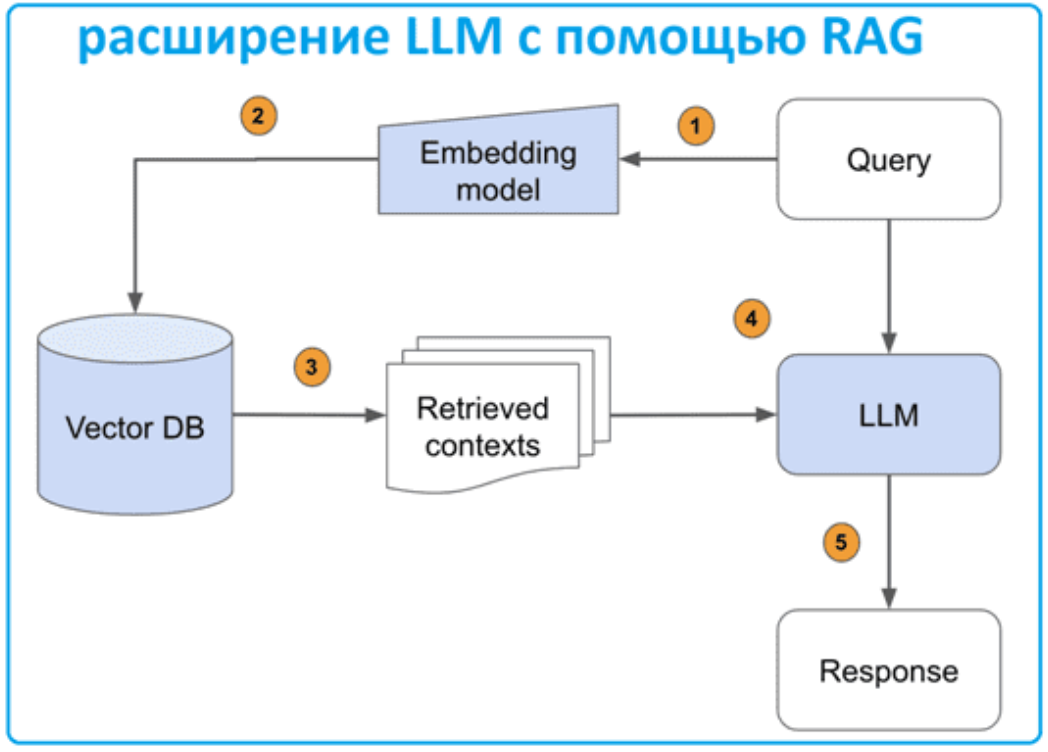

Engineering and Infrastructure

The 2025 AI Engineering Report

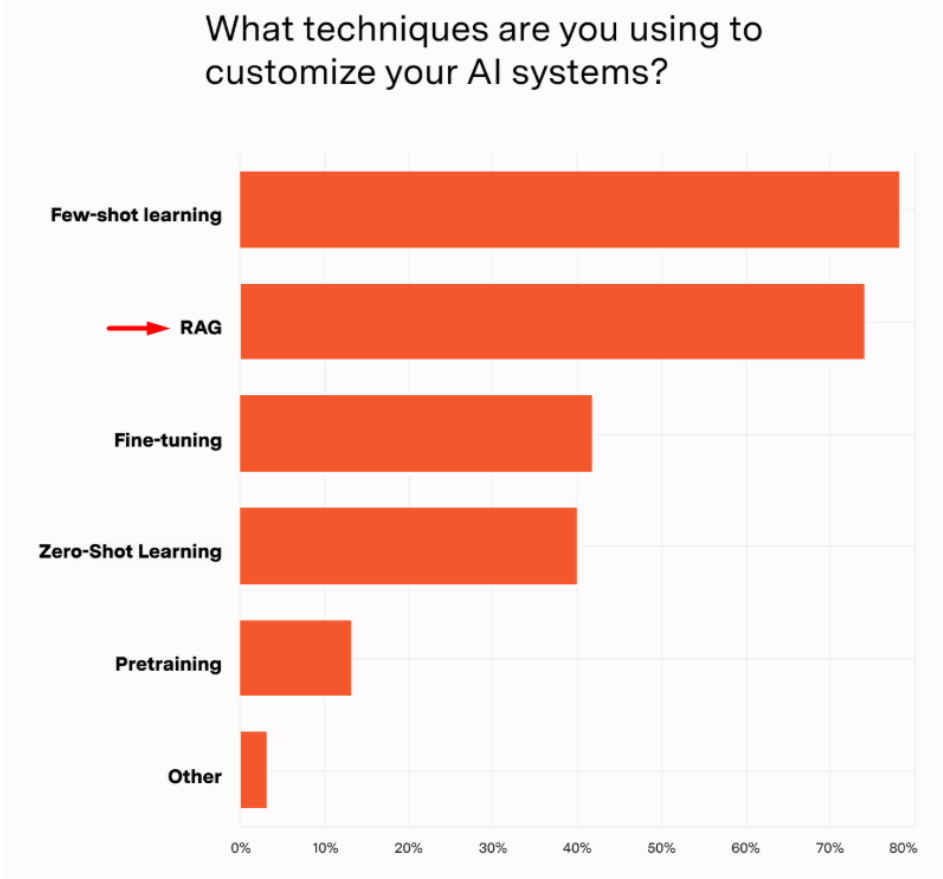

Retrieval Augmented Generation (на пальцах)

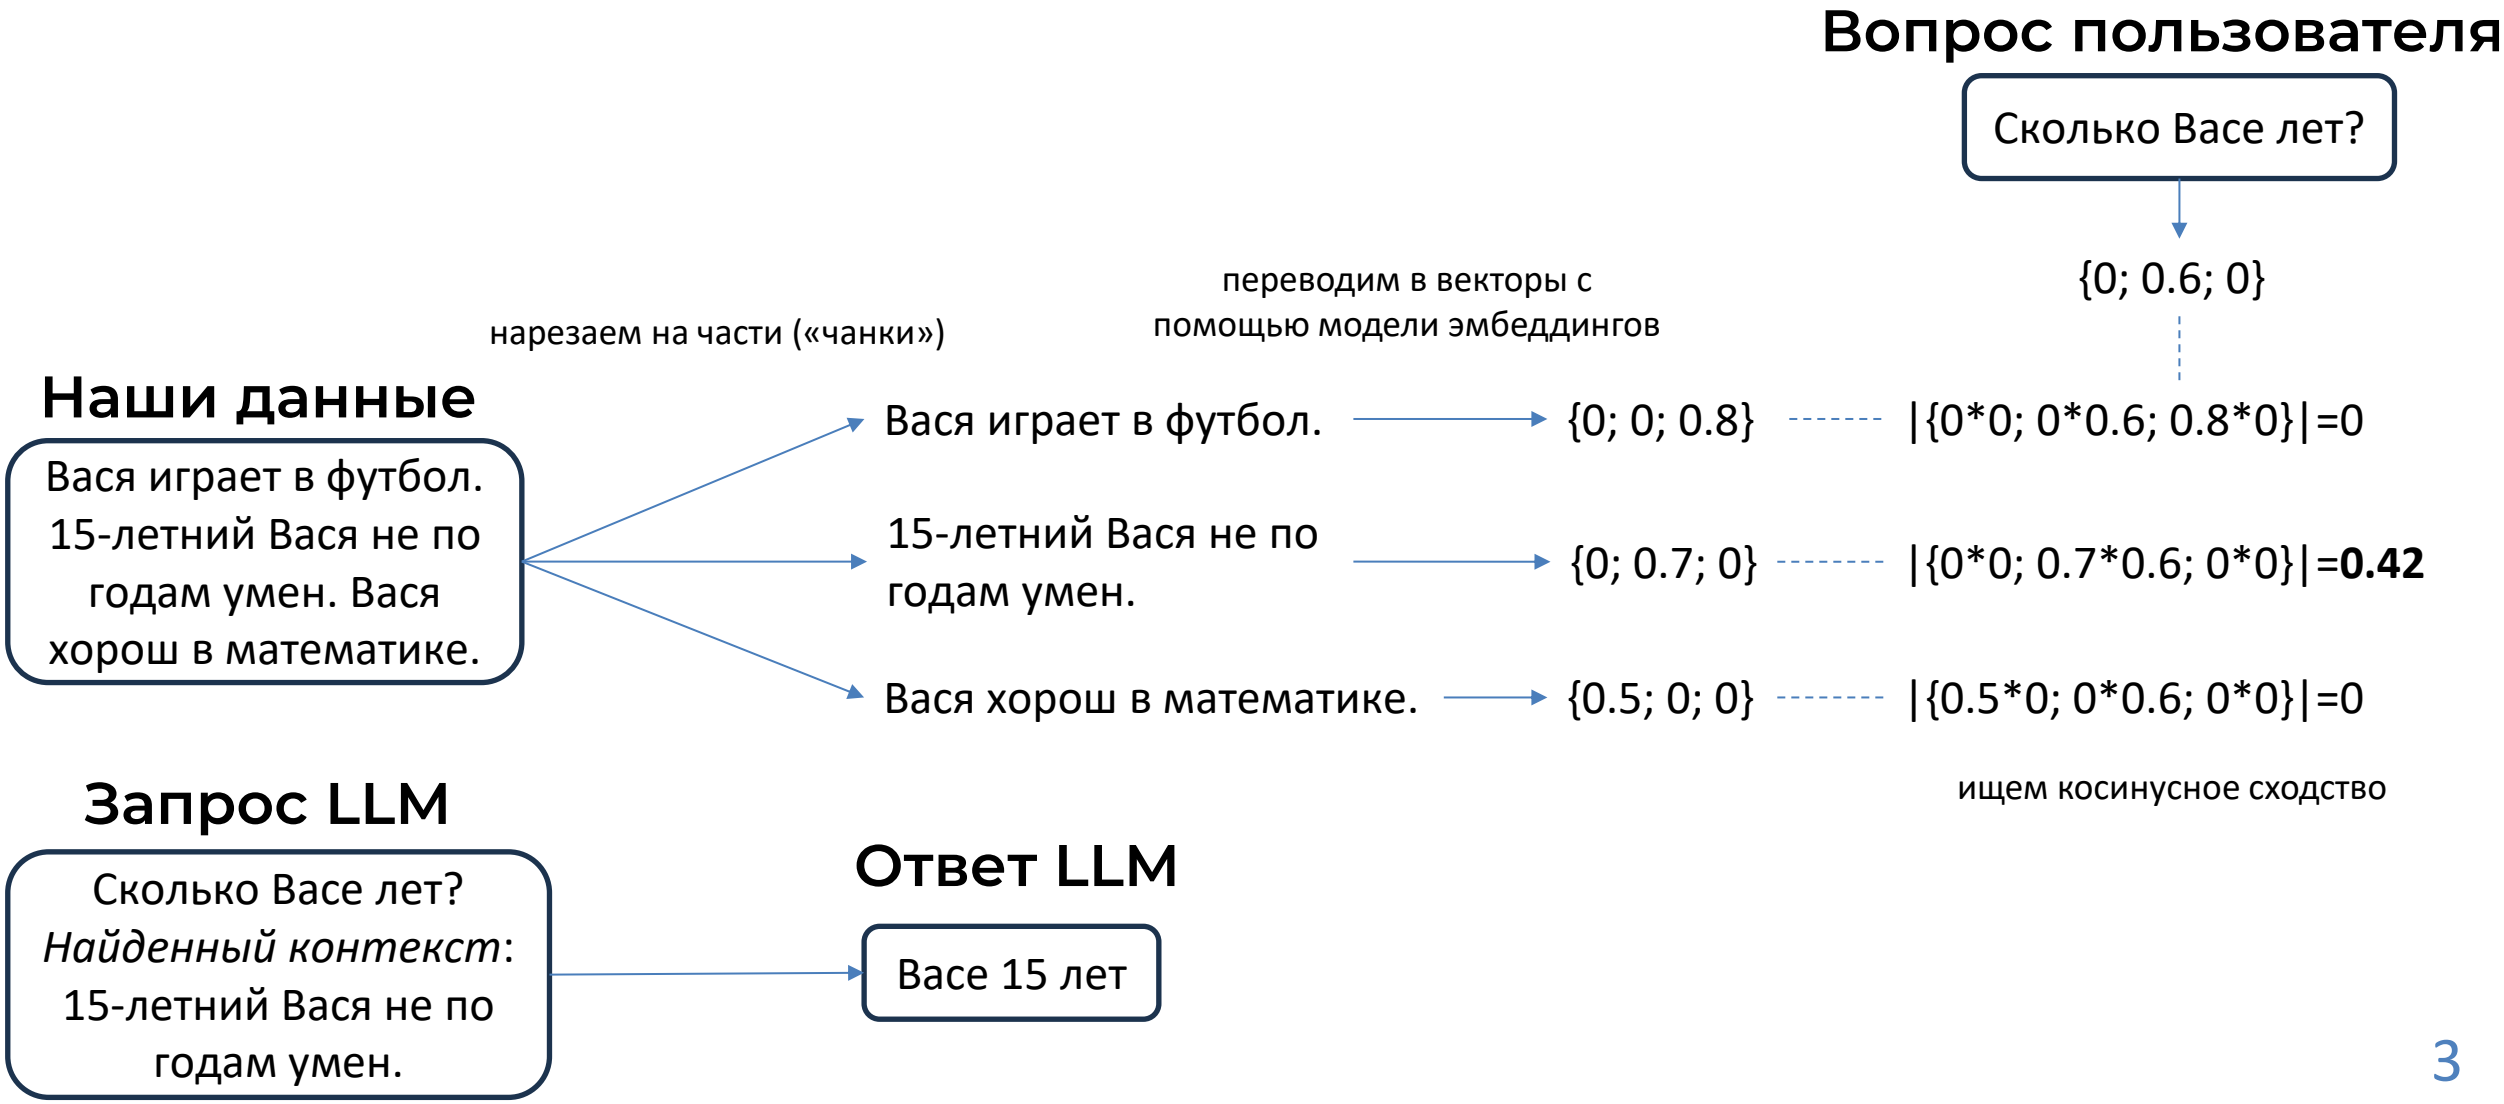

Retrieval Augmented Generation (если погружаться)

HyDE

RAG-Fusion

Haystack

LlamaIndex

Langchain

Knowledge Graph

MMR

TrueLens

RAGAS

Agentic RAG

Recall@k

BM25 + TF-IDF

Contextual Retrieval

Neo4j

Cross-Encoder Reranking

HNSW

IVF-Flat

AutoRAG

Multi-Query

ColBERT

DeepEval

CRAG

Enterprise RAG Challenge v2 (2025)

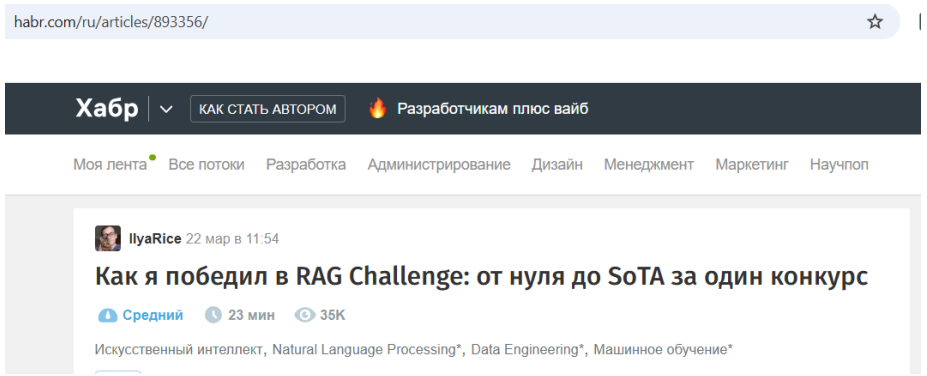

Статья получила международную популярность и была переведена на английский и китайский:

Конкурс на деньги (как и в случае с Kaggle) – часто лучший способ определить state-of-the-art техники.

В чём суть RAG Challenge?

Нужно создать вопросно-ответную систему на основе годовых отчётов компании. Если коротко, то в день конкурса:

1. Выдаётся 100 годовых отчётов по случайно выбранным компаниям и 2.5 часа на их парсинг и составление базы данных. Отчёты представляют из себя PDF размером до 1000 страниц.
2. После этого генерируется 100 случайных вопросов (по заранее известным шаблонам), на которые система должна как можно быстрее ответить.

Все вопросы должны иметь однозначный ответ:

- Да/Нет;
- название компании (или нескольких компаний);
- названия управляющих позиций, выпущенных продуктов;
- размер той или иной метрики: выручка, количество магазинов и т.д.

Каждый ответ должен сопровождаться ссылками на страницы с ответом в качестве доказательства, что система по честному нашла ответ и не сгаллюцинировала.

Enterprise RAG Challenge v2 (условия)

100 PDF годовых отчетов компаний (случайно отобранных)

100 случайных вопросов (Да/Нет; Числовые показатели и т.д.)

Оценивался Retrieval (верная ссылка в ответе) и Generation (верный ответ)

Итоговая метрика R/3 + G (т.е. верный ответ оценивался в 3 раза выше верного цитирования)

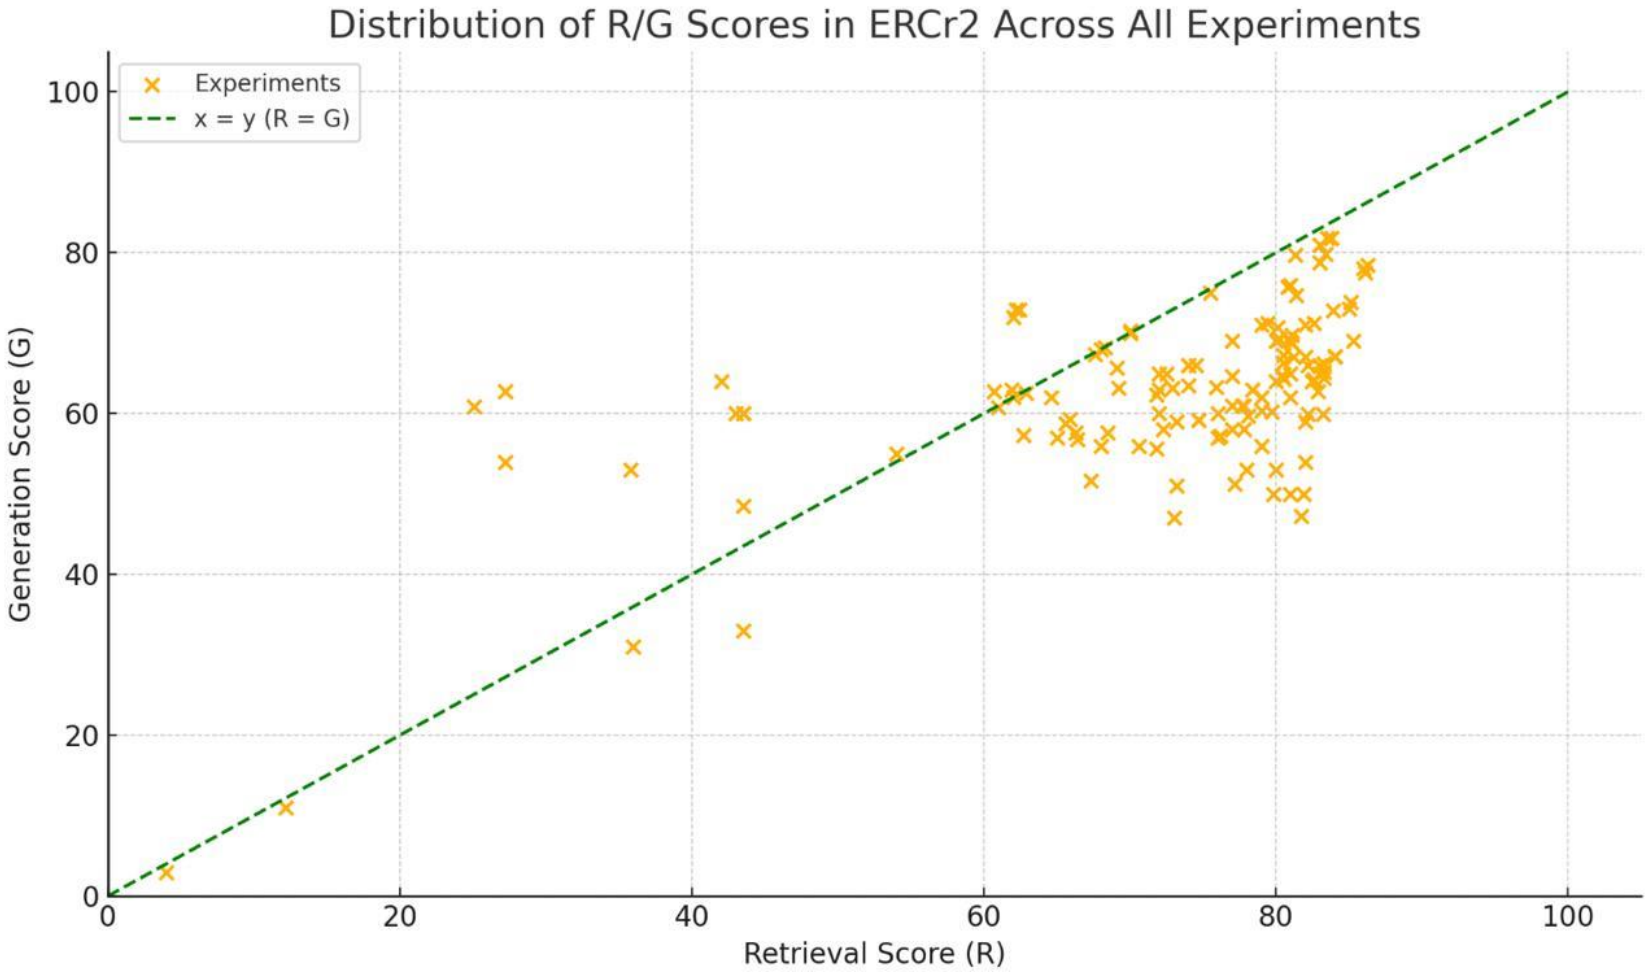

https://t.me/llm_under_hood/617

Enterprise RAG Challenge v2. Победное решение (кратко)

Team / Experiment	Time	R/G	Score
1. ▶ Ilia Ris	49 min	83/81	123.7
2. ▶ Emil Shagiev	55 min	86/78	121.6
3. ▶ Dmitry Buykin	8 hours	81/76	117.5
4. ▶ Sergey Nikonov	30 hours	85/73	116.4
5. ▶ ScrapeNinja.net	23 hours	82/71	112.5
6. ▶ xsl777	16 hours	79/71	110.9
7. ▶ nikolay_sheyko(grably.tech)	25 hours	81/69	110.4
8. ▶ Felix-TAT	7 days	80/69	109.4
9. ▶ A.Rasskazov/V.Kalesnikau	30 hours	84/67	109.3
10. ▶ Dany the creator	3 hours	82/67	108.4
11. ▶ SergC	7 days	77/69	108.1
12. ▶ Swisscom Innovation Lab	21 hours	83/66	107.8
13. ▶ fomih	10 days	83/65	107.4
14. ▶ Al Bo	12 days	81/65	105.9
15. ▶ NumericalArt	8 days	70/70	105.3

всего около 45 команд

Схема победного решения Ilia Ris

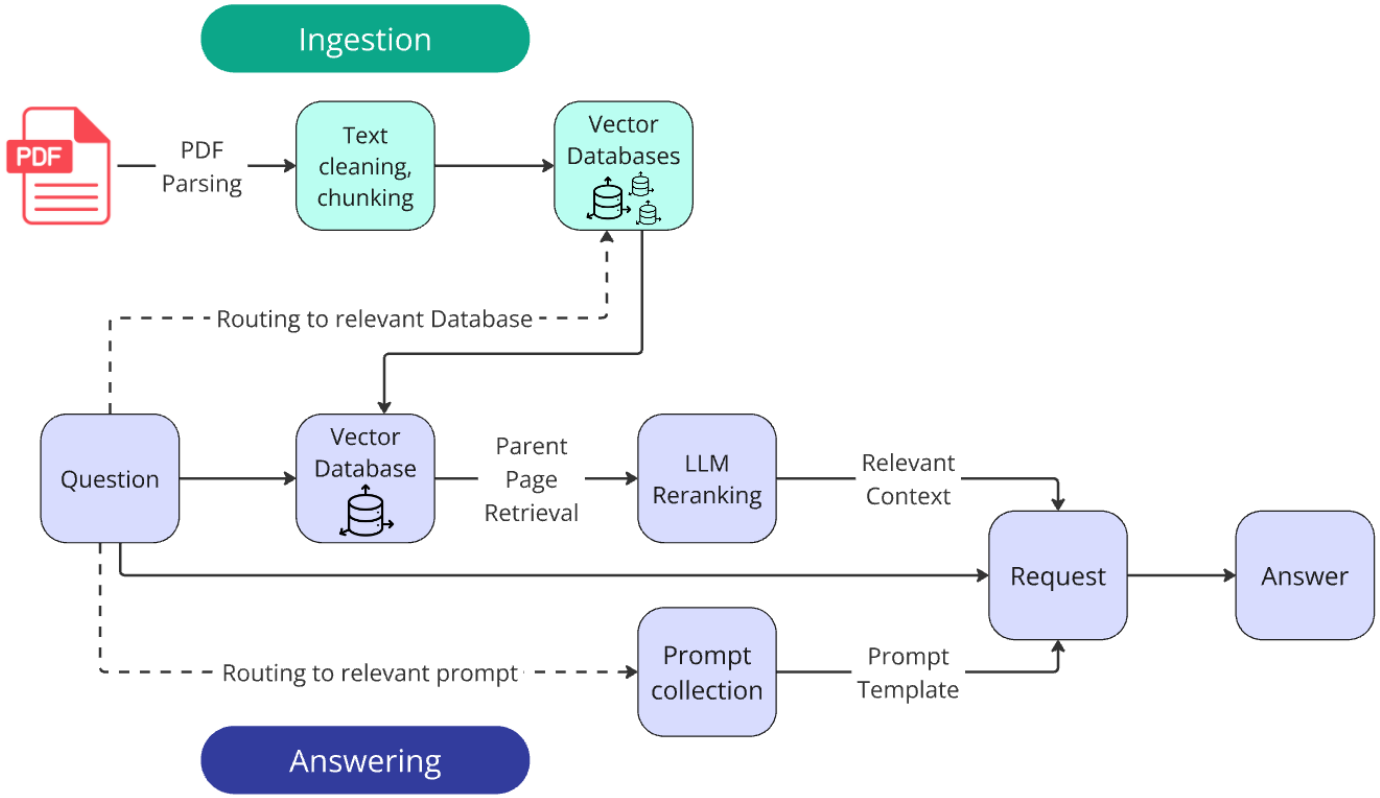

На доп. треке IBM (использование open-source LLM Llama 2 70B) качество просело менее, чем на 2%!

Parsing

JSON

помимо самого текста хранится идентификатор документа и номер страницы (в дальнейшем понадобится для роутинга и parent-page enrichment)

Markdown
(дальше его и используем для чанкинга)

Html
(про запас; если понадобится заново обработать сложную таблицу, например)

Илья использовал Docling, арендовав сервер на Runpod. Можно также использовать Unstructured, Marker, LlamaParse и пр.

В своем упрощенном примере я использовал pdfplumber.

Ingestion

Markdown текст → (рекурсивный md сплиттер) → **Чанки текста по 300 токенов с перекрытием по 50 токенов** → (text-embedding-3-large) → FAISS

\+

metadata.json (какой чанк на какой странице для будущего parent page enrichment)

Для каждого отчета создавалась своя векторная база данных

Как работает рекурсивный md сплиттер:

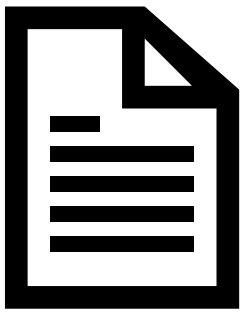

страница → (режем по пустым строкам (/n/n)) → Абзац 1 (пустая строка) Абзац 2 (пустая строка) … Абзац n → (Если чанки все еще больше 300 токенов, режем по строкам, потом по словам, потом по символам) → Чанки не более 300 токенов

Retrieval

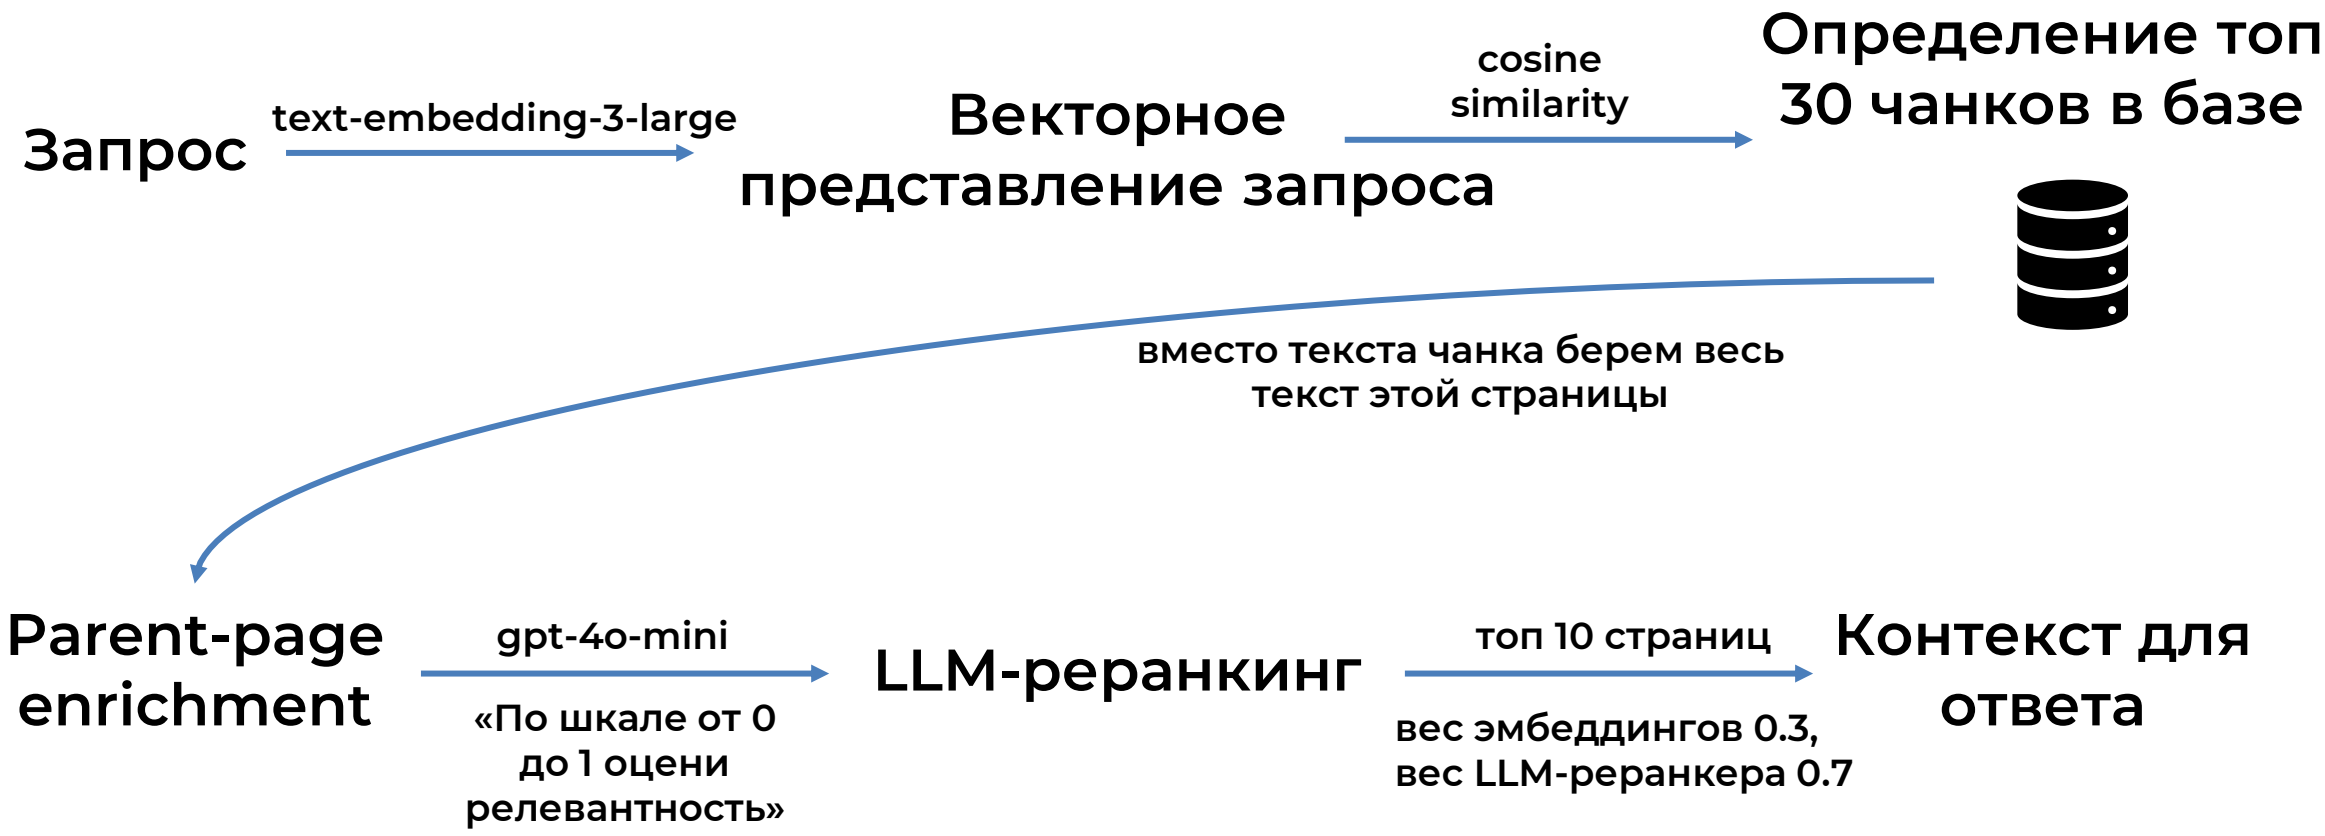

LLM-реранкинг – перспективная новинка! Обычно используется cross-encoder reranking.

Серебряный призер вообще построил RAG без эмбеддингов.

Augmentation

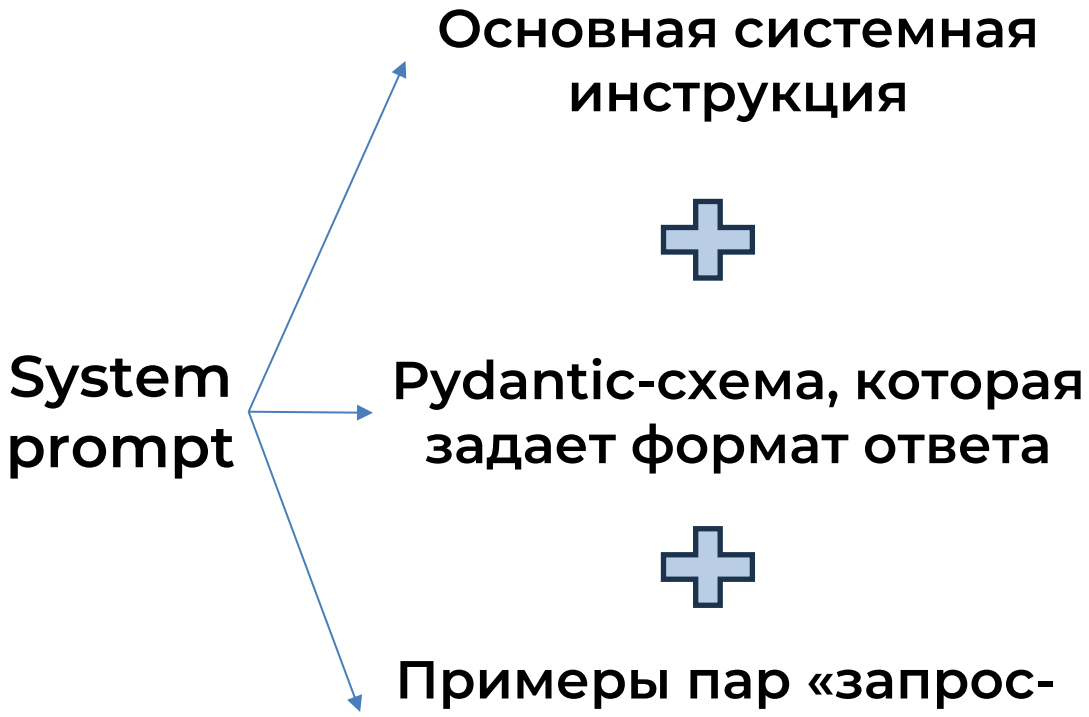

User prompt → Template для вставки контекст и вопроса

Ты — RAG (Retrieval-Augmented Generation) система ответов. Твоя задача — отвечать на заданный вопрос, опираясь ТОЛЬКО на информацию из годового отчёта компании, который предоставляется как релевантные страницы (контекст) после процедуры RAG.
Перед финальным ответом внимательно, вслух и по шагам проанализируй вопрос. (и т.д.)

step_by_step_analysis: str = Field(description="
Подробный пошаговый анализ ответа минимум из 5 шагов и не менее 150 слов."
str = Field(description="Краткое резюме пошагового анализа. Около 50 слов.") (и т.д.)

Пример 1: Какова прибыль Сбера за 2023 год?
{"step_by_step_analysis": «…»,"reasoning_summary": «…»,
"relevant_pages": …, "final_answer": …}

Контекст: (найденный контекст, т.е. отобранные страницы)
Вопрос: (вопрос)

Generation

Специфическое для условий данного соревнования решение:

- **каждый запрос (кроме multiquery) касался только одного отчета;**
- **в запросе было явно указано, к отчету какой компании он относится;**
- **запросы относились к одному из нескольких известных типов.**

1. Роутинг к нужной БД по имени компании

Отчет Сбера

2. Роутинг к нужному шаблону промпта

Шаблон промпта, где ответ – одно число

3. Роутинг multiquery запросов

И дальше как в п.1 и п.2

Ещё раз соберем всё решение вместе

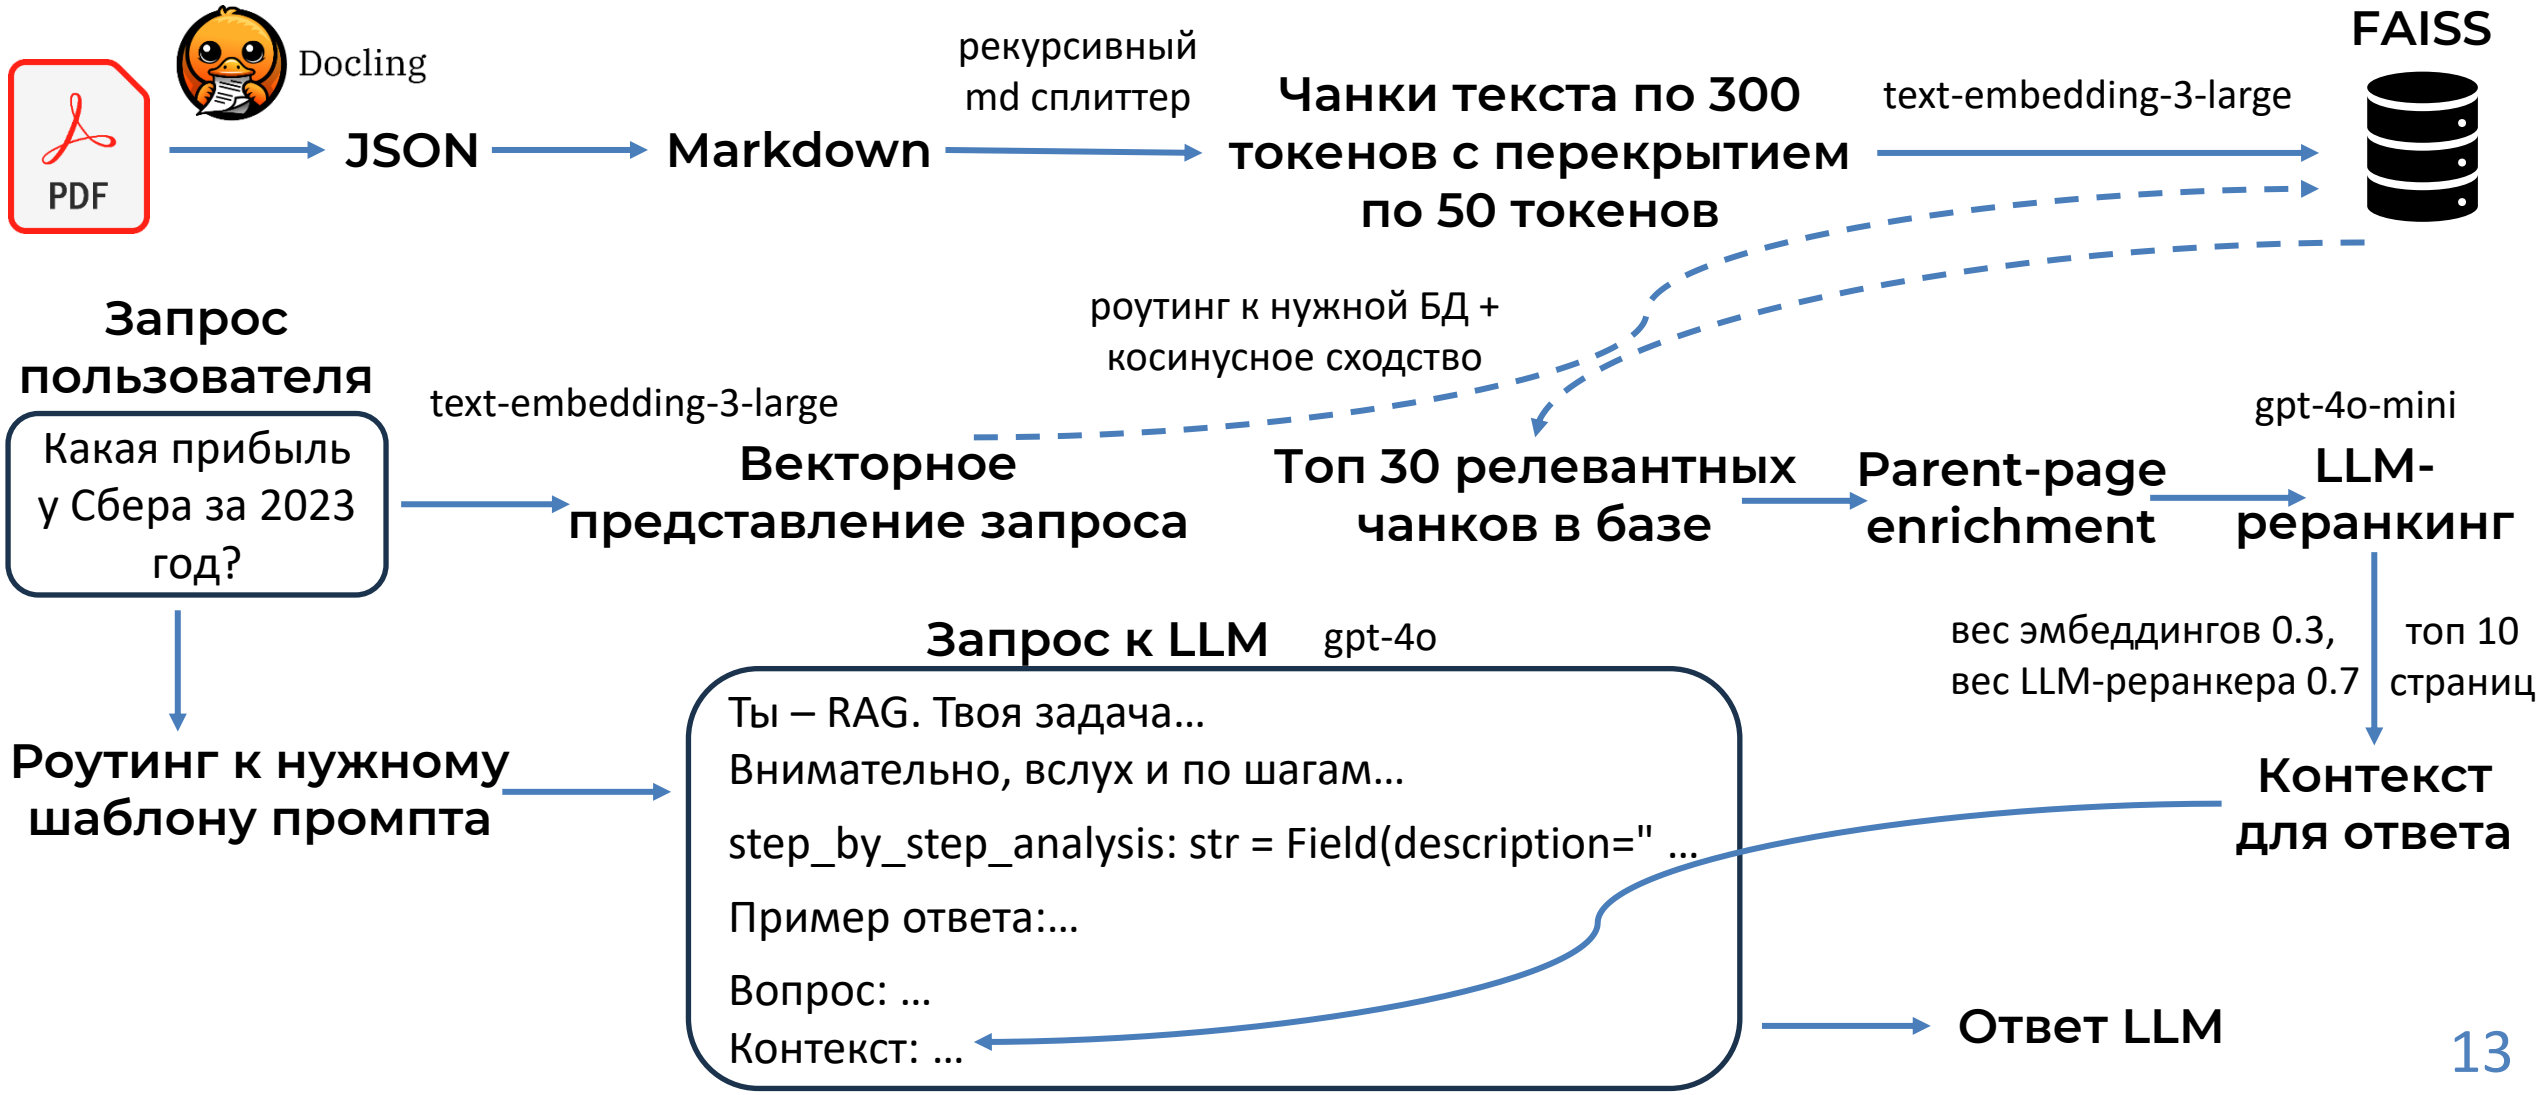

Упрощенная адаптация (курсовой проект автора презентации, развернут на HF)

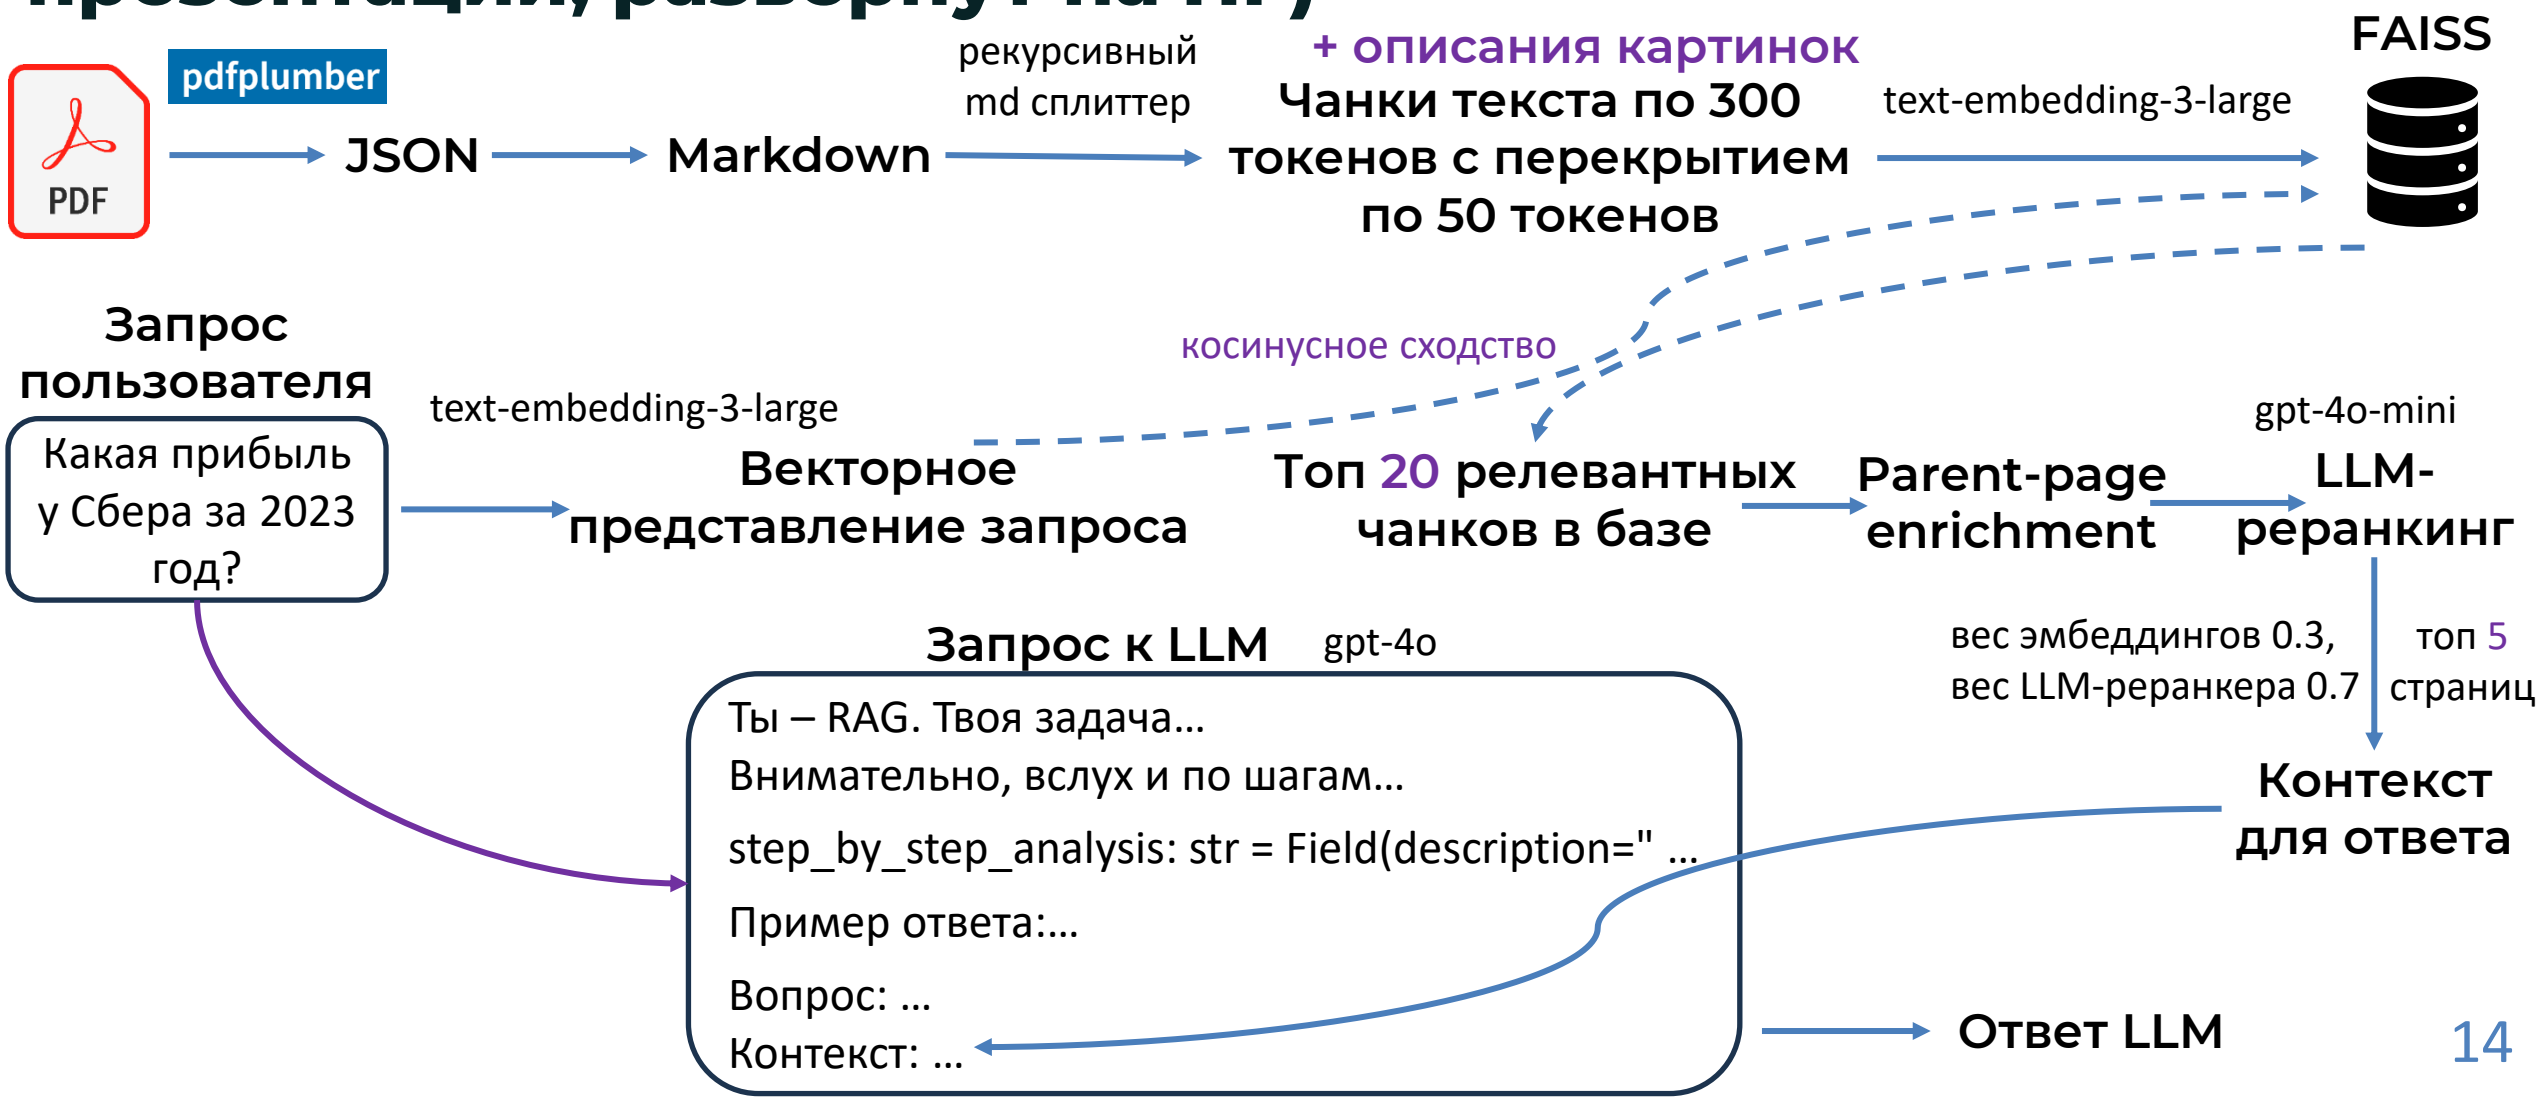

Demo

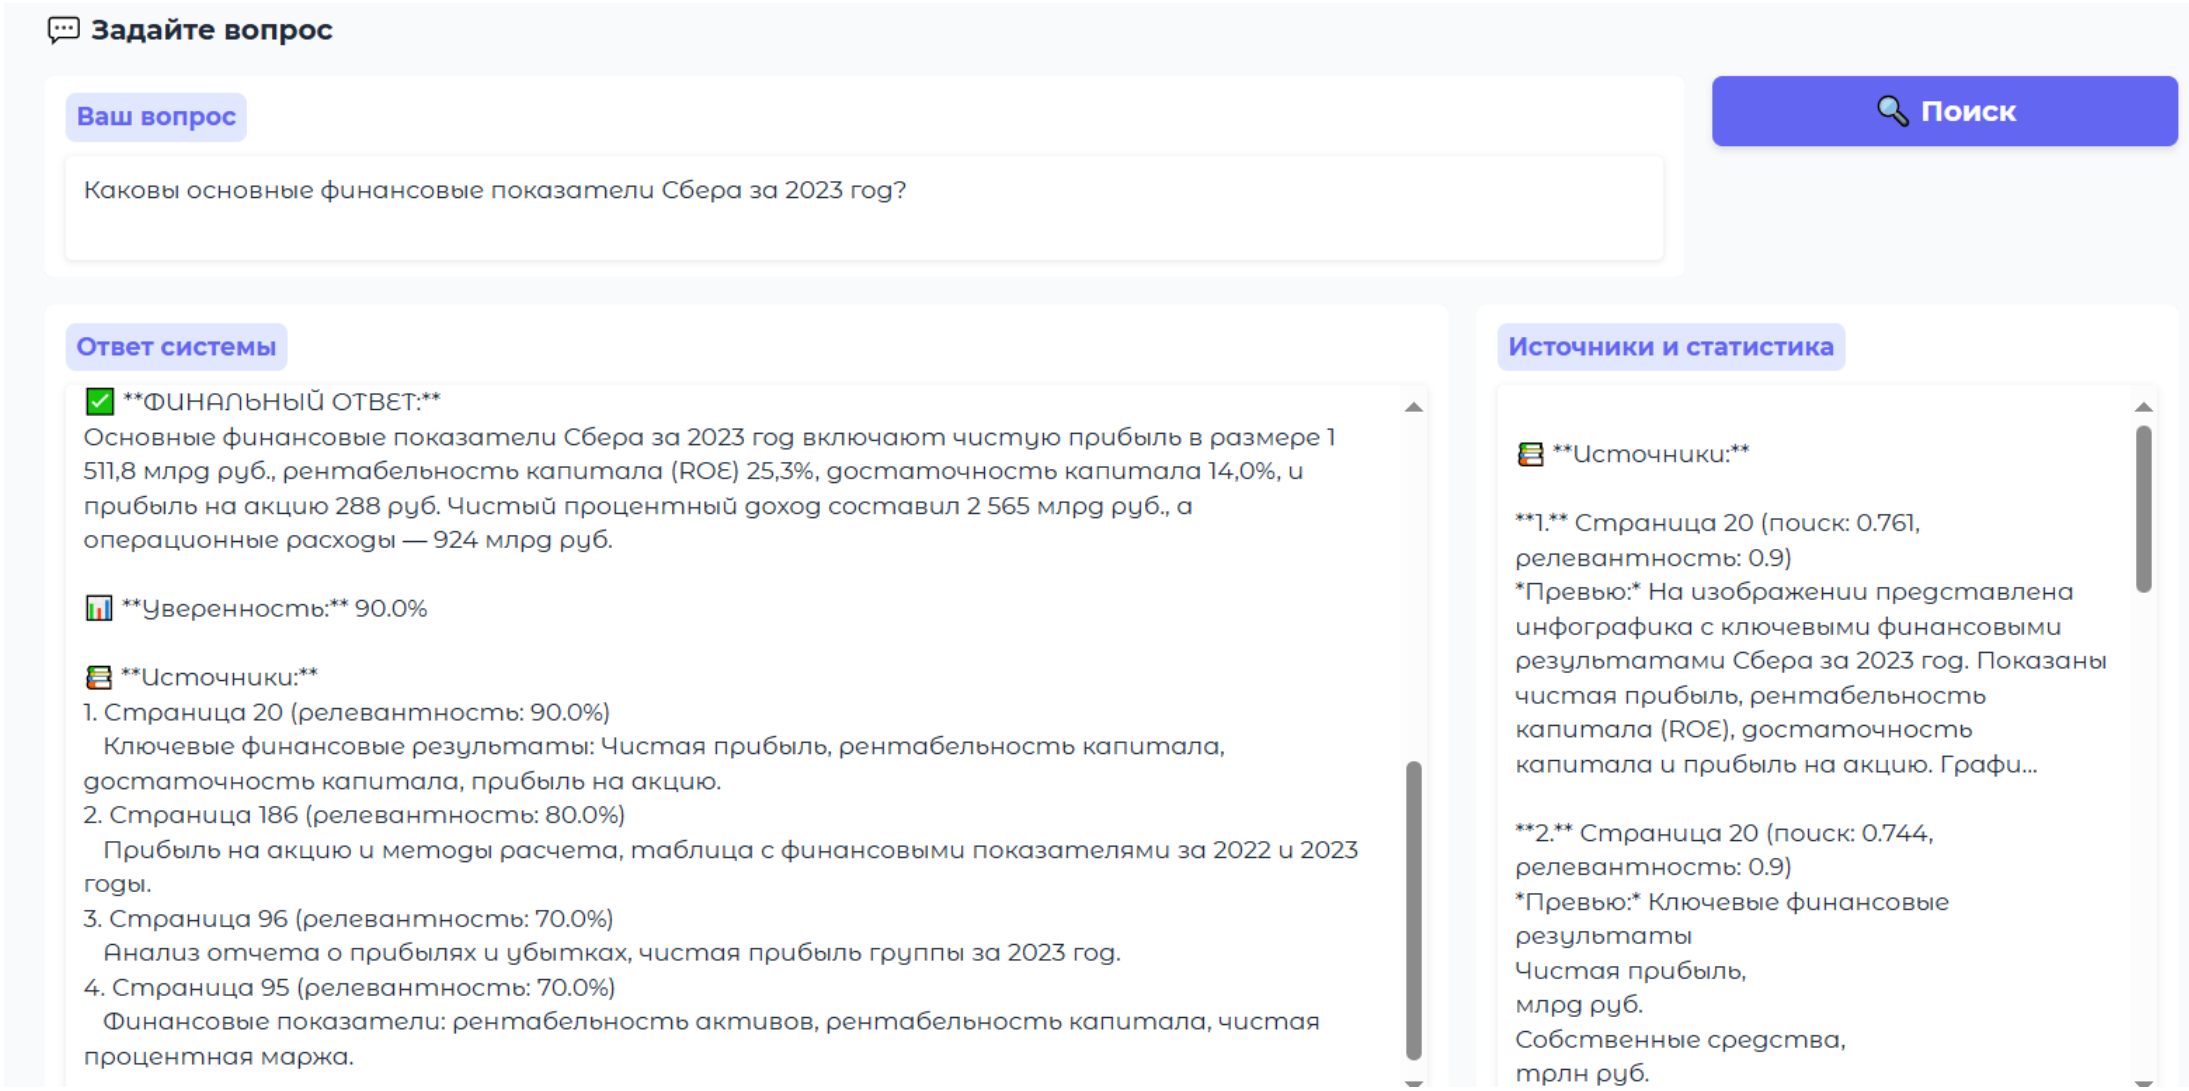

Скриншот развернутой на HuggingFace мультимодальной RAG-системы

Решение серебряного призера

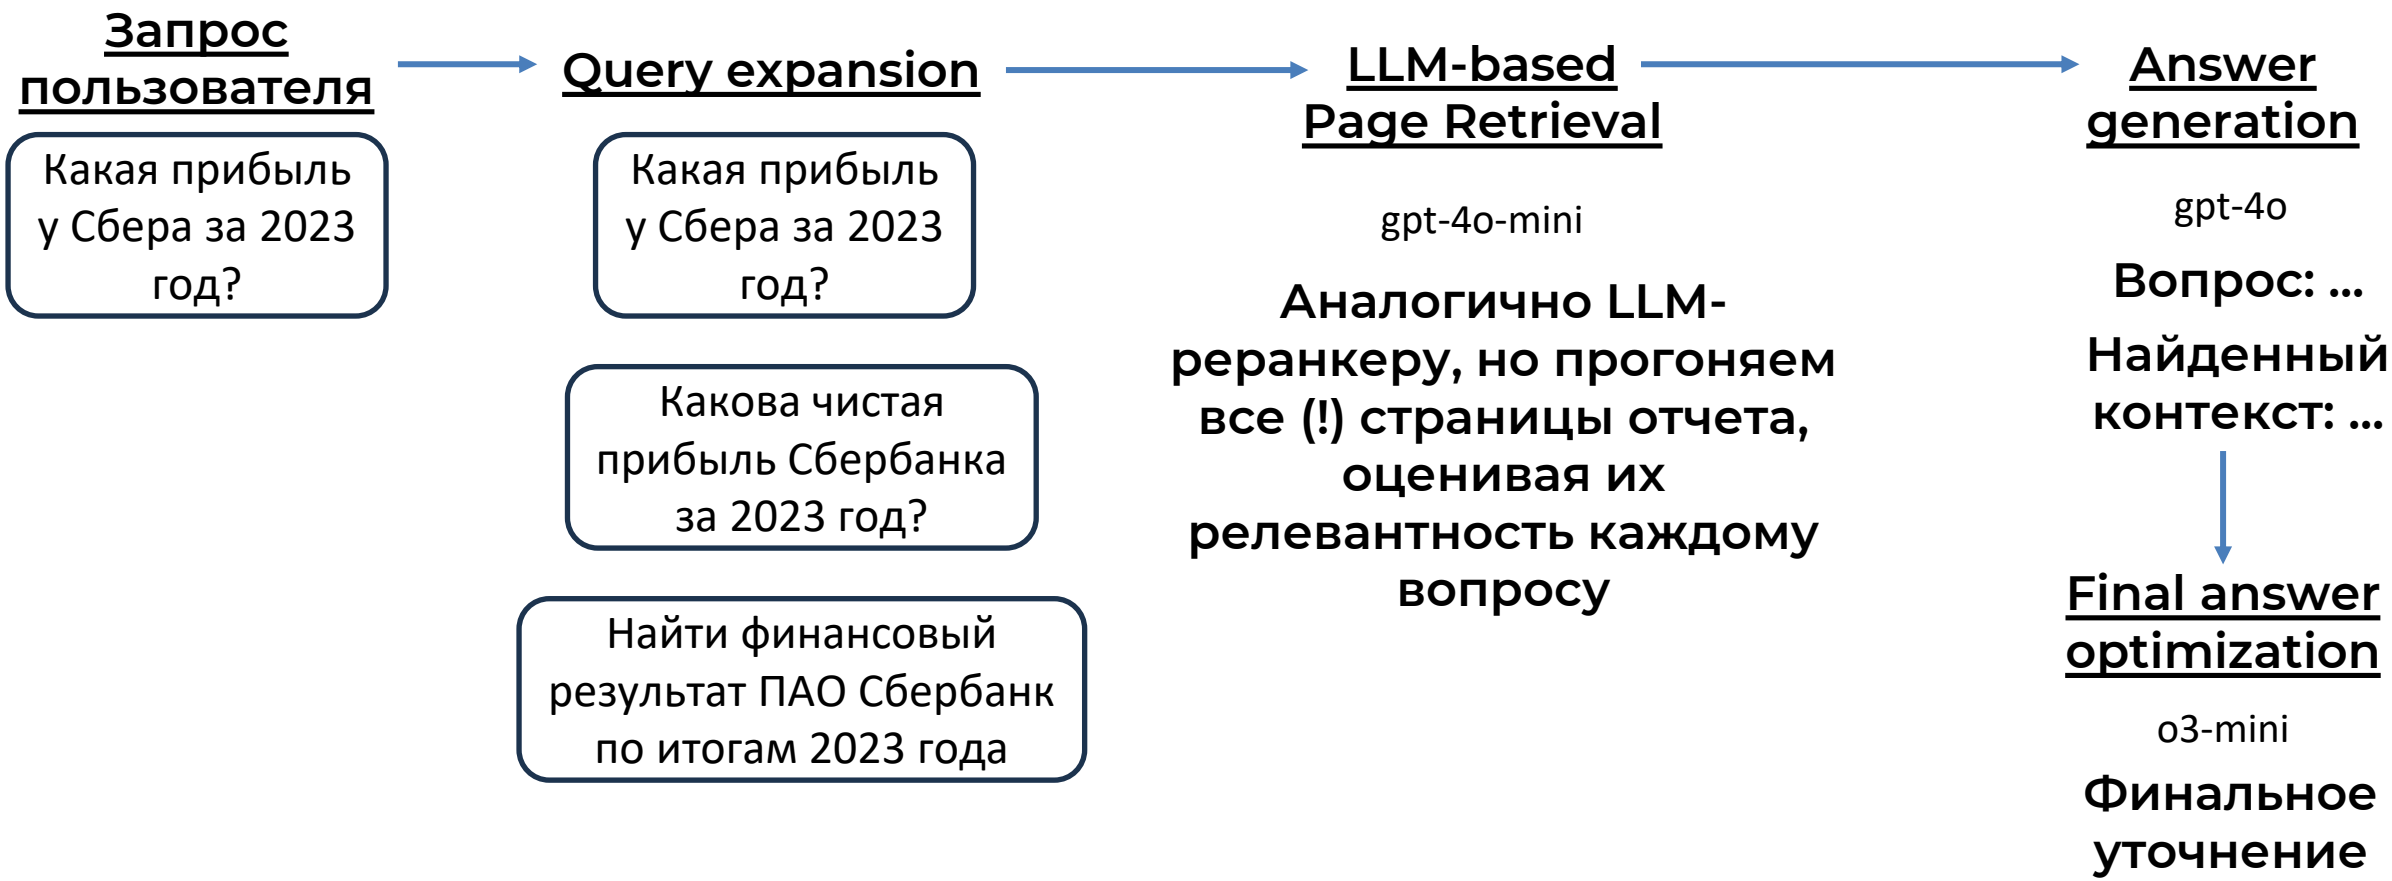

Стало сенсацией, что можно построить эффективный RAG вообще без эмбеддингов, а на ставших дешевыми и быстрыми, но при этом достаточно качественными для оценки релевантности LLM!

Что еще свежего почитать / за чем следить (на июль 2025 г.)

SIGIR 2025 LiveRAG Challenge

Завершился 17 июля 2025 г.

https://liverag.tii.ae/

https://arxiv.org/abs/2506.14516

https://github.com/rmit-ir/G-RAG-LiveRAG

Соревнование по веб-поиску по сути

CRAG-MM Challenge

Завершится 5 августа 2025 г.

https://www.aicrowd.com/challenges/meta-crag-mm-challenge-2025

Мультимодальный RAG

Бенчмарк DRAGON

Запущен 25 июля 2025 г.

https://habr.com/ru/companies/sberbank/articles/931000/

https://huggingface.co/spaces/ai-forever/rag-leaderboard

Enterprise RAG Challenge v3

анонсирован

https://t.me/llm_under_hood/536

В третьем раунде можно сделать поинтереснее.

Во первых мы **заранее наберем бизнес-документов из разных отраслей**, публичных либо вручную анонимизированных - контракты, договоры, требования. Это уже будут не абстрактные годовые отчеты, а что-то более применимое и востребованное.

Общий формат соревнования будет тем же самым - нужно будет автоматически дать ответы на набор сгенерированных вопросов по этим документам, сопроводив их ссылками на подтверждающие факты. Вместо ссылки на номер страницы, как это было во втором раунде, надо будет приводить **доказательство с указанием на конкретный элемент документа** в рамках семантической схемы (она похожа на то, как Docling извлекает структуру).

Например, если ответ в таблице (а таких документов станет больше) - нужно будет привести название строки, столбца и конкретное значение. Если ответ на графике - примерный bbox. Если ответ - это пункт в контракте, то номер пункта и его текст. Так мы будем проверять, насколько правильно RAG находит исходные данные.

Дальше начинается самое интересное. Мы вместе **разработаем модульный стенд для прогона всего пайплайна и оценки результатов**, опубликуем его заранее с набором данных для оценки. Каждый сможет взять код, форкнуть, попробовать что-то улучшить и сразу посмотреть на результаты. Это было то самое конкурентное преимущество, которое помогло Илье занять первое место во втором раунде.

Выводы

- RAG – одно из основных применений LLM на сегодняшний день.
- Data Science соревнования – один из лучших способов определить наиболее эффективные техники решения задач.
- Победное решение Enterprise RAG Challenge v2 (2025) показало свою эффективность как на больших проприетарных, так и на небольших open source LLM, и победило в обоих треках соревнования – а потому заслуживает изучения и тестирования.
- Качественный Retrieval критически важен.
- LLM-реранкинг, Structured Output, Chain-of-thoughts применялись во многих топ-решениях соревнования.
- Если вы и ваша команда не являетесь профессионалами в RAG или не имеете достаточно ресурсов / времени для реализации и проверки множества различных новомодных RAG-пайплайнов, то адаптация победного решения Enterprise RAG Challenge v2 (2025) является прекрасным обоснованным решением.

Источники

- «Как я победил в RAG Challenge: от нуля до SoTA за один конкурс» (https://habr.com/ru/articles/893356/)
- Github-репозиторий победного решения (https://github.com/IlyaRice/RAG-Challenge-2)
- Сайт организатора соревнования Enterprise RAG Challenge (https://www.timetoact-group.at/en/insights/the-winner-of-the-enterprise-rag-challenge)
- Упрощенная адаптация (курсовой проект автора презентации) (https://huggingface.co/spaces/DmitrySpb/RAG_Webinar)
- Telegram-канал Рината Абдуллина (t.me/llm_under_hood)

Спасибо за внимание!

По любым вопросам: