ИТМО

TTT-Memory: Параметр-эффективная адаптация LLM

Существующий подход

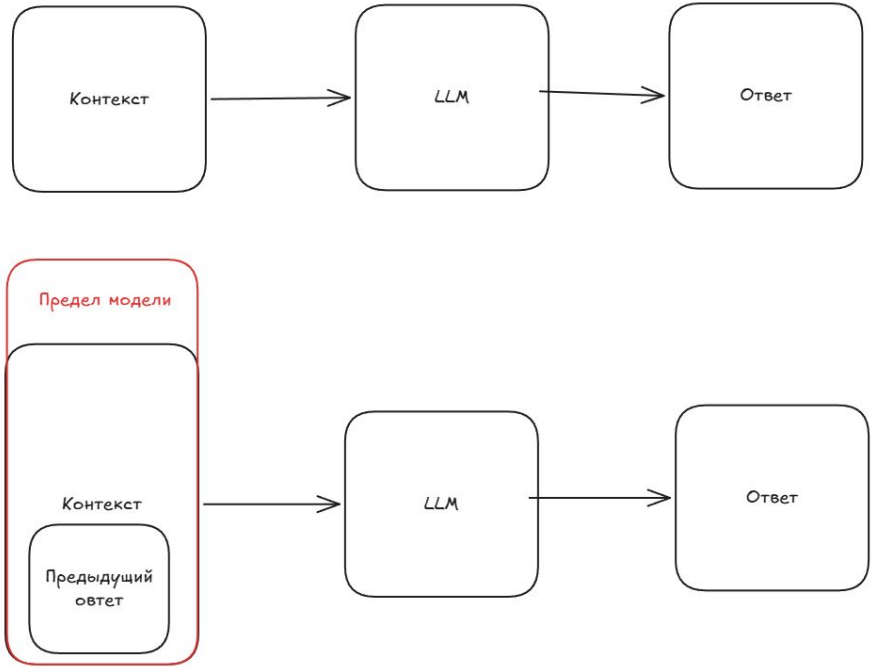

Новый подход: Test Time Training

ИТМО

СТАНДАРТ

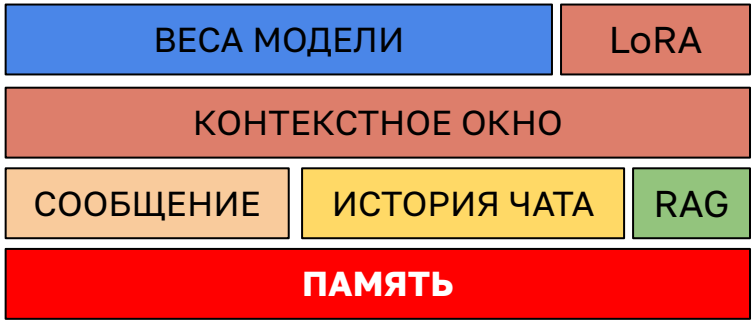

Количество информации, которые помнит модель зависит от размера контекстного окна

НАШ ПОДХОД

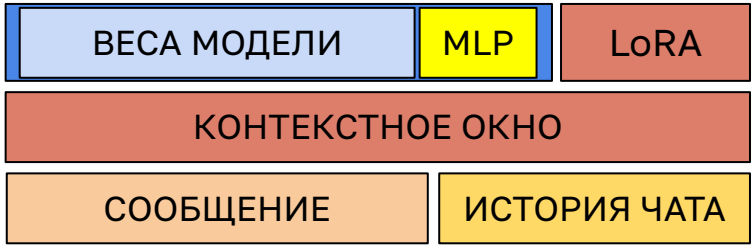

НЕ ЗАВИСИМ ОТ КОНТЕКСТНОГО ОКНА

MLP ОБУЧАЕТСЯ НА INFERENCE

ПАМЯТЬ

Test time training

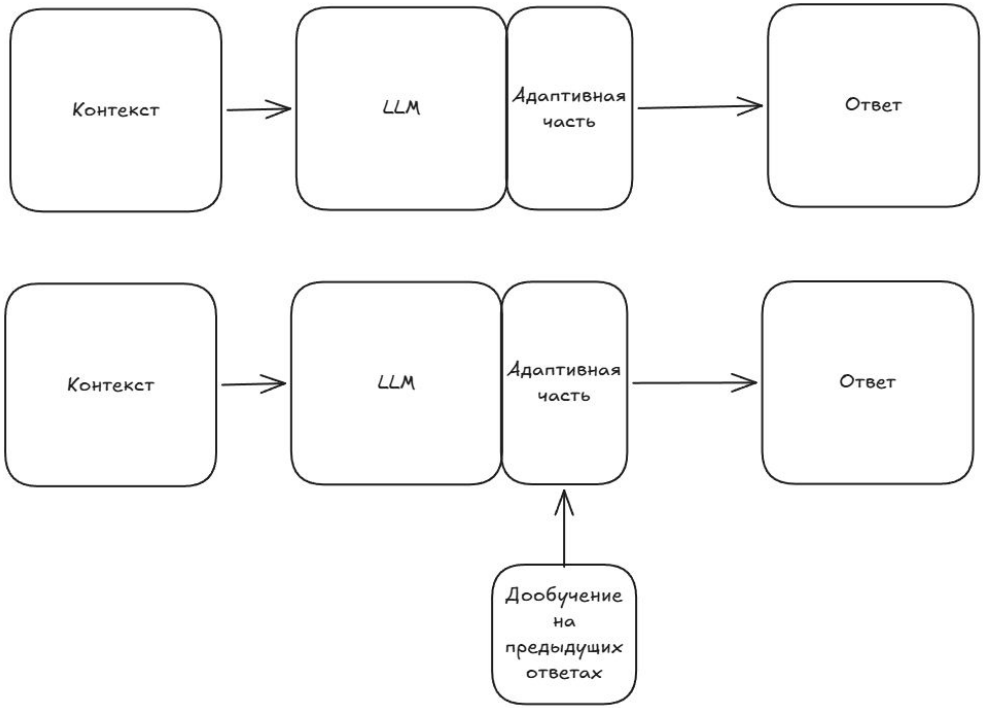

https://arxiv.org/pdf/2512.23675

Test time training

Предлагаемый подход:

- Позволит сократить размер контекстного окна LLM, без значимой потери исторического контекста.
- Позволит модели дообучаться в ходе общения, “глубже” адаптироваться к диалогу.
- Позволит получать ответы лучшего качества при аналогичных затратах.

Что есть сейчас

- Подготовлен репозиторий с базовой архитектурой модели
- Проведены тесты проверки LOSS-адаптации
- Была получена модель исследовательского размера (10M)
- Проведены тесты памяти

https://github.com/Spart911/TTT-memory

Риски и Стратегия Mitigation

ИТМО

Poisoning (Отравление памяти)

Риск: Пользователь может специально «научить» модель вредным инструкциям.
Mitigation: Санитизация входа, ограничение нормы обновления весов.

Compute Overhead

Риск: Расчет градиентов на инференсе нагружает GPU.
Mitigation: Оптимизированные CUDA-ядра, гибридные схемы.

Privacy (GDPR/152-ФЗ)

Риск: «Забыть» данные из весов сложнее, чем удалить запись из БД.
Mitigation: Selective Unlearning и хранение только дельт.

Цель: Proof of Concept

- Воспроизведение архитектуры на инфраструктуре Сбера (125M параметров)
- Обучение на обезличенных диалогах (до 50 000 сессий)
- Сравнение полученной архитектуры с существующими подходами

Необходимые ресурсы

GPU

(минимум 24GB GPU) для экспериментов.

Data

Анонимизированные логи операторов (Dataset: 50k диалогов).

Team

Команда студентов ИТМО (5 чел) + 1 Sber Senior Mentor (20% времени).

Перспективы

- Масштабирование модели до 1.5B+ параметров
- Переход к решению, готовому к интеграции в ИИ-инструменты Сбера

Экономика

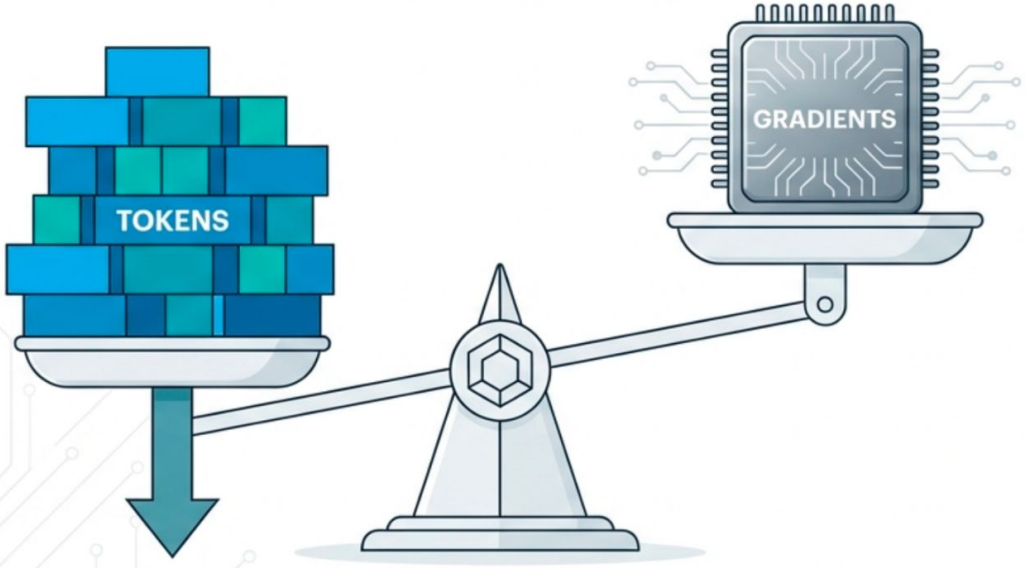

Стоимость растет линейно (20k... 128k)

Стоимость константна (O(1))

2.7x

Ускорение инференса (TTT-E2E) по сравнению с full attention на контексте 128k.

Традиционный метод заставляет платить за каждый токен истории при каждом запросе. TTT требует вычислительной мощности для обновления весов, но экономит на обработке гигантских контекстов. Для длинных диалогов TTT становится экономически выгоднее.

Контакты

@NYUROPRINTS

@TRIPPLEVAN

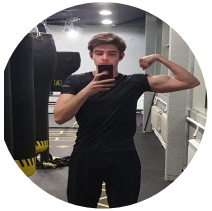

@ELIK_SIR

@EGORRTAR

@XIVXIVS

Спасибо за внимание!

ITsMOre than a UNIVERSITY

Ваши контакты